Laporan Ujian Tengah Semester Data Science
Semester Ganjil Tahun Ajaran 2026/2027

PREDIKSI KELAYAKAN MINUM (POTABILITAS) AIR BERDASARKAN INDIKATOR PARAMETER KIMIAWI AIR

Disusun oleh:

Kelompok Datadoom

1. Mahendra Rajwaa Putra Pamungkas (123240039)
2. Muhammad Athalla Bagaskara (123240212)
3. Ryan Haqqi Prarista (123240067)
4. Muhammad Ridho Hikmatul Maulana (123240218)

Dosen Pengampu:

Dhimas Arief Dharmawan

PROGRAM STUDI INFORMATIKA
JURUSAN INFORMATIKA
FAKULTAS TEKNIK INDUSTRI
UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN"
YOGYAKARTA

2026

DAFTAR ISI

1. Business Understanding 1
1.1 Latar Belakang 1
1.2 Pernyataan Masalah 2
1.3 Identifikasi dan Pemetaan Stakeholder 2
1.4 Tujuan SMART 4
1.5 Metrik Keberhasilan 5
1.6 Asumsi dan Batasan 6
1.7 Risiko dan Etika 7
1.8 Nilai Bisnis dan Use Case 7
1.9 Kesesuaian Antar-Komponen Business Understanding 8
1.10 Kerangka Metodologi CRISP-DM dan Rencana Tahap Lanjutan 8
2. Data Understanding 10
2.1 Sumber Data dan Lisensi 10
2.2 Data Dictionary 11
2.3 Pemeriksaan Kualitas Data 11
2.4 Exploratory Data Analysis 13
2.5 Nilai Kosong dan Outlier 18
2.6 Representativitas dan Bias 19
2.7 Ringkasan Data Understanding 20
Daftar Pustaka 21
Lampiran 23
Lampiran A. Verifikasi Informasi PPT terhadap Berkas CSV 23
Lampiran B. Catatan Asumsi dan Keterbatasan 23
Lampiran C. Dokumentasi Prosedur Analisis dan Reproduksibilitas 23

DAFTAR TABEL

Tabel 1. Stakeholder penelitian prediksi potabilitas air 3
Tabel 2. Pemetaan stakeholder terhadap karakteristik data 3
Tabel 3. Tujuan SMART penelitian..... 4
Tabel 4. Metrik keberhasilan dan target awal 5
Tabel 5. Hasil prediksi dan konsekuensinya 5
Tabel 6. Risiko, dampak, dan rencana mitigasi 7
Tabel 7. Skenario penggunaan hasil prediksi 8
Tabel 8. Keterkaitan komponen Business Understanding 8
Tabel 9. Status fase CRISP-DM pada laporan UTS 9
Tabel 10. Identitas dan sumber dataset 10
Tabel 11. Data dictionary 11
Tabel 12. Nilai kosong per kolom 11
Tabel 13. Statistik deskriptif fitur 12
Tabel 14. Potensi outlier menurut aturan IQR dan Z-score 13
Tabel 15. Distribusi kelas Potability 13
Tabel 16. Perbandingan fitur menurut kelas dan korelasi dengan target 16
Tabel 17. Proporsi kelas layak pada baris dengan dan tanpa nilai kosong 18
Tabel 18. Temuan Data Understanding dan implikasinya 20
Tabel 19. Verifikasi klaim PPT terhadap data aktual 23
Tabel 20. Prosedur analisis dan lingkungan 23

DAFTAR GAMBAR

Gambar 1. Jumlah nilai kosong per fitur 12
Gambar 2. Distribusi kelas Potability 14
Gambar 3. Histogram dan estimasi kepadatan setiap fitur 15
Gambar 4. Sebaran setiap fitur menurut kelas Potability 16
Gambar 5. Korelasi Pearson setiap fitur dengan Potability 17
Gambar 6. Matriks korelasi Pearson antarvariabel 18

1. Business Understanding

1.1 Latar Belakang

Air minum yang aman merupakan prasyarat kesehatan masyarakat. *World Health Organization* (WHO, 2022) menyusun pedoman kualitas air minum yang menjadi dasar penetapan regulasi dan standar keamanan air di banyak negara. Di Indonesia, persyaratan kesehatan lingkungan, termasuk kualitas air, diatur melalui Peraturan Menteri Kesehatan Nomor 2 Tahun 2023 sebagai peraturan pelaksanaan Peraturan Pemerintah Nomor 66 Tahun 2014 tentang Kesehatan Lingkungan (Kementerian Kesehatan Republik Indonesia, 2023). Secara spesifik, Lampiran Bab II peraturan tersebut menetapkan Standar Baku Mutu Kesehatan Lingkungan untuk Media Air Minum, yang mencakup parameter fisik (seperti kekeruhan maksimal 3 NTU dan total padatan terlarut/TDS maksimal 300 mg/L) serta parameter kimia (seperti derajat keasaman pH pada rentang 6,5–8,5 dan sisa klor 0,2–0,5 mg/L).

Penilaian potabilitas secara konvensional bergantung pada pengambilan sampel dan analisis laboratorium atas banyak parameter. Pendekatan ini akurat, tetapi menuntut waktu, biaya reagen, dan tenaga terlatih sehingga frekuensi pemantauan di banyak lokasi menjadi terbatas. Rancangan kelompok (PPT Progress 1) menyebut waktu uji laboratorium sekitar 2–5 hari; angka ini belum disertai sumber sehingga dalam laporan ini diperlakukan sebagai gambaran umum, bukan fakta yang telah diverifikasi. Rentang waktu tersebut sejalan dengan standar waktu tunggu (turnaround time) laboratorium penguji mutu air, di mana pengujian lengkap (termasuk inkubasi mikrobiologi bakteri coliform selama 24–48 jam serta analisis instrumental kimia) umumnya membutuhkan waktu 3 hingga 7 hari kerja sebelum Laporan Hasil Uji (LHU) resmi diterbitkan. Dalam konteks tersebut, *data science* dapat berperan sebagai alat penapisan awal (*screening*): model mempelajari pola dari parameter yang relatif cepat diukur untuk membantu memprioritaskan sampel yang perlu diuji lebih lengkap.

Dataset yang dipilih memuat sembilan parameter fisik dan kimia air, yaitu pH, *hardness*, *solids*, *chloramines*, *sulfate*, *conductivity*, *organic carbon*, *trihalomethanes*, dan *turbidity*, beserta label potabilitas biner. Parameter-parameter tersebut lazim dibahas dalam pedoman kualitas air; sebagian berkaitan dengan penerimaan konsumen (rasa dan kejernihan), sebagian lain dengan proses disinfeksi dan produk sampingnya (WHO, 2022). Dalam Bab 8 dan Bab 12 pedoman WHO (2022), parameter kekeruhan (turbidity) dan TDS (solids) dikaitkan erat dengan aspek estetika dan efektivitas desinfeksi, sedangkan kloramin (chloramines) dan trihalometana (trihalomethanes) diatur sebagai indikator residu disinfektan dan senyawa sampingan klorinasi

yang berpotensi karsinogenik bila melebihi ambang batas aman. Penelitian terdahulu pada dataset dengan jumlah observasi yang sama menunjukkan bahwa tugas ini tidak sepele: Lisdiana dan Setiawan (2026) melaporkan bahwa berbagai model berbasis pohon keputusan dengan seluruh fitur hanya mencapai akurasi sekitar 0,58–0,65 pada data uji, dan mengidentifikasi nilai kosong sebagai tantangan utama.

Penelitian ini menguji seberapa jauh sembilan parameter tersebut dapat memprediksi label potabilitas, membandingkan dua algoritma kandidat (*Random Forest* dan *XGBoost*), dan mengidentifikasi parameter yang paling berpengaruh. Hasil prediksi diposisikan sebagai alat bantu penapisan awal, bukan pengganti uji laboratorium maupun standar kualitas air yang berlaku. Laporan UTS ini mencakup fase *Business Understanding* dan *Data Understanding*; fase berikutnya disajikan sebagai rencana (Subbab 1.10).

1.2 Pernyataan Masalah

Pemantauan potabilitas air melalui uji laboratorium lengkap tidak selalu dapat dilakukan sering dan merata, sedangkan keputusan operasional sering membutuhkan indikasi awal yang cepat. Masalah yang diangkat adalah bagaimana memanfaatkan parameter fisik dan kimia air yang tersedia untuk memprediksi status potabilitas secara otomatis sebagai penapis awal, dengan perhatian khusus pada kesalahan yang paling berbahaya, yaitu air yang sebenarnya tidak layak minum tetapi diprediksi layak. Rumusan masalah penelitian adalah sebagai berikut.

1. Seberapa baik parameter fisik-kimia air dalam dataset dapat memprediksi status potabilitas air?
2. Algoritma klasifikasi mana, di antara *Random Forest* dan *XGBoost*, yang memberikan kinerja terbaik, terutama dalam meminimalkan air tidak layak minum yang terprediksi layak?
3. Parameter apa yang paling berpengaruh terhadap prediksi potabilitas?

Analisis data diperlukan karena parameter air saling berinteraksi dan tidak selalu dapat dinilai melalui ambang tunggal per parameter. Namun, pendekatan yang diusulkan memiliki keterbatasan yang harus dinyatakan sejak awal: (a) dataset tidak memuat parameter mikrobiologis maupun logam berat; (b) label potabilitas tidak disertai dokumentasi cara penetapannya; (c) sebagian nilai pada tiga fitur kosong; dan (d) hasil pada dataset ini belum tentu berlaku pada sumber air lain. Karena itu, model diposisikan sebagai pendukung keputusan, bukan penentu keputusan.

1.3 Identifikasi dan Pemetaan Stakeholder

Pedoman proyek mengharuskan stakeholder yang berpeluang terlibat dijelaskan secara jelas. Tabel 1 merangkum stakeholder yang diusulkan dalam PPT Progress 1 beserta kebutuhan informasi, manfaat, dan keterbatasannya. Perlu dibedakan antara pihak yang benar-benar terlibat dalam penelitian ini dan pihak yang hanya berstatus *potensial*. Berdasarkan bahan yang tersedia, hanya tim peneliti (Kelompok Datadoom) yang terlibat langsung; pihak lain adalah calon pengguna yang diusulkan dan belum dilibatkan melalui wawancara atau validasi kebutuhan. Oleh karena itu, kebutuhan informasi pada tabel berikut merupakan asumsi kerja yang perlu divalidasi pada tahap selanjutnya.

Tabel 1. Stakeholder penelitian prediksi potabilitas air

Stakeholder	Status	Peran dan kebutuhan informasi	Manfaat potensial	Keterbatasan
PDAM dan penyedia air bersih	Potensial (diusulkan)	Memantau mutu air sebelum didistribusikan; membutuhkan indikasi cepat air yang mencurigakan.	Memprioritaskan sampel untuk uji lengkap; pemantauan lebih sering.	Tidak menggantikan uji resmi; ketersediaan sembilan parameter di lapangan belum dikaji; belum divalidasi pada data lokal.
Depot air isi ulang dan industri makanan-minuman	Potensial (diusulkan)	Memverifikasi kelayakan air baku secara berkala.	Deteksi dini pergeseran kualitas air baku.	Parameter mikrobiologis tidak tercakup; kemampuan mengukur seluruh parameter belum tentu dimiliki.
Dinas Kesehatan dan instansi lingkungan hidup	Potensial (diusulkan)	Mengawasi kepatuhan standar dan merumuskan kebijakan pencegahan.	Alat bantu menentukan prioritas lokasi pengambilan sampel.	Keputusan regulatif tetap memerlukan hasil uji resmi; prediksi tidak dapat menjadi bukti tunggal.
Konsumen dan masyarakat umum	Potensial (penerima manfaat tidak langsung)	Membutuhkan jaminan air aman.	Manfaat tidak langsung melalui pengawasan yang lebih baik.	Hasil model tidak boleh dipakai langsung untuk memutuskan apakah air aman dikonsumsi.
Analis data dan peneliti (Kelompok Datadoom; dosen pengampu sebagai penilai)	Terlibat langsung	Mempelajari pola parameter dan menguji keandalan model yang dapat direproduksi.	Portofolio dan alur kerja yang dapat dijalankan ulang.	Dataset publik dengan dokumentasi asal-usul yang terbatas.

Sumber: PPT Progress 1 Kelompok Datadoom (slide 3), dikembangkan dan dikritisi oleh penulis.

Slide 9 PPT juga menyebut peran yang lebih rinci, yaitu teknisi lapangan PDAM, insinyur pengolahan air, analis kualitas air, BPBD, dan tenaga medis. Peran-peran ini dipetakan terhadap

karakteristik data pada Tabel 2, yang sekaligus menunjukkan bahwa kualitas data tiap kelompok variabel berbeda dan memengaruhi seberapa andal informasi tersebut bagi stakeholder terkait.

Tabel 2. Pemetaan stakeholder terhadap karakteristik data

Kelompok variabel	Stakeholder terkait (PPT)	Relevansi bagi stakeholder	Catatan dari data aktual
pH, Turbidity, Solids	Konsumen dan teknisi lapangan PDAM	Berkaitan dengan aspek yang dapat dirasakan atau diamati (keasaman, kejernihan, padatan terlarut).	pH memiliki 491 nilai kosong (14,99%); Turbidity dan Solids lengkap.
Chloramines, Sulfate, Trihalomethanes	Insinyur pengolahan air	Memantau efektivitas disinfeksi dan residu produk sampingnya.	Sulfate kosong 23,84% dan Trihalomethanes 4,95%; Chloramines lengkap.
Conductivity, Organic_carbon, Hardness	Dinas lingkungan hidup dan analis kualitas air	Indikator kandungan mineral dan bahan organik.	Ketiganya lengkap (tidak ada nilai kosong).
Potability dan probabilitas prediksi	Manajemen PDAM, BPBD, tenaga medis	Acuan awal keputusan penyaluran dan tindakan pencegahan.	Label tanpa dokumentasi penetapan; 39,01% sampel berlabel layak.

Sumber: PPT Progress 1 (slide 9) dan hasil analisis penulis atas water_potability.csv.

1.4 Tujuan SMART

Tujuan penelitian disusun mengikuti kerangka SMART dan bersumber dari PPT Progress 1; target numerik tidak diubah. Tabel 3 memuat rumusan tiap aspek beserta catatan penyusun.

Tabel 3. Tujuan SMART penelitian

Aspek	Rumusan tujuan	Catatan penyusun
Specific	Membangun model klasifikasi biner (*Random Forest* dan *XGBoost*) untuk memprediksi potabilitas (layak = 1, tidak layak = 0) dari sembilan parameter air: pH, Hardness, Solids, Chloramines, Sulfate, Conductivity, Organic Carbon, Trihalomethanes, dan Turbidity.	Nama kolom pada CSV adalah *Organic_carbon* dan *ph*; seluruh sembilan fitur terkonfirmasi.
Measurable	Pada *test set*: F1-score ≥ 70%, ROC-AUC ≥ 0,75, dan *precision* kelas layak ≥ 72%.	Target awal yang diusulkan kelompok; F1-score kelas layak (kelas 1) ditetapkan sebagai metrik utama didampingi Macro F1. Angka target ini sejalan dengan kisaran kinerja yang dilaporkan dalam literatur pemodelan potabilitas air (El-Bacha & Salhi, 2025; dirujuk pula dalam Lisdiana & Setiawan, 2026).

Aspek	Rumusan tujuan	Catatan penyusun
Achievable	Menggunakan dataset 3.276 baris dari Kaggle dengan pandas, scikit-learn, dan XGBoost melalui *preprocessing* terstruktur (imputasi, penanganan *outlier*, penskalaan, *hyperparameter tuning*).	Jumlah baris terkonfirmasi. Keterlaksanaan teknis wajar, tetapi ketercapaian target kinerja belum dapat diasumsikan: sinyal univariat antara fitur dan label pada data sangat lemah (Subbab 2.4).
Relevant	Mendukung SDG ke-6 (air bersih dan sanitasi) dan menyediakan alat penapis awal yang murah bagi pengelola air.	Klaim "murah" merupakan hipotesis; belum diuji.
Time-bound	Seluruh siklus CRISP-DM diselesaikan sesuai linimasa proyek semester ganjil 2026/2027.	Pengumpulan UTS (Oktober 2026) mencakup Business Understanding dan Data Understanding; dilanjutkan Data Preparation dan Modeling (November 2026), serta Evaluation dan Deployment menjelang UAS (Desember 2026–Januari 2027) sesuai linimasa perkuliahan.

Sumber: PPT Progress 1 (slide 4) dan pedoman proyek UTS; catatan oleh penulis.

1.5 Metrik Keberhasilan

Permasalahan ini adalah klasifikasi biner dengan kelas yang tidak seimbang (kelas tidak layak 60,99% dan kelas layak 39,01%, lihat Subbab 2.4.1). Akurasi saja tidak memadai karena prediksi seluruh sampel sebagai "tidak layak" sudah menghasilkan akurasi 60,99%. Pemilihan metrik pada Tabel 4 mengikuti PPT dengan beberapa catatan.

Tabel 4. Metrik keberhasilan dan target awal

Metrik	Target PPT	Fungsi	Catatan
F1-score	≥ 0,70	Metrik utama; menyeimbangkan *precision* dan *recall*.	Ditetapkan F1-score kelas layak (kelas 1) sebagai metrik target utama untuk menyeimbangkan presisi dan recall kelas target, didampingi Macro F1 untuk menilai performa kedua kelas secara adil.
Precision kelas layak	≥ 0,72	Menekan *false positive* (air tidak layak diprediksi layak).	Pembanding acak: *precision* ≈ prevalensi kelas layak (0,39).
Recall kelas tidak layak	Belum ada	Memastikan air tercemar terdeteksi.	Secara matematis sama dengan 1 − *false positive rate* (FPR); sebaiknya diberi target numerik.
ROC-AUC	≥ 0,75	Kemampuan memisahkan kelas pada seluruh ambang.	Tidak bergantung pada satu ambang keputusan.
FPR dan *confusion matrix*	Minimal	Menilai kesalahan paling berbahaya melalui *threshold tuning*.	Ambang dipilih pada data validasi, bukan data uji.
Balanced accuracy dan PR-AUC	Tidak ada	Pelengkap pada data tidak seimbang.	Usulan penyusun; bukan bagian rancangan PPT.

Sumber: PPT Progress 1 (slide 2 dan 5); catatan oleh penulis.

Risiko kesalahan prediksi tidak setara. Tabel 5 menjelaskan empat hasil prediksi. *False positive* (air tidak layak yang diprediksi layak) adalah kesalahan paling berbahaya karena dapat membuat air yang tidak aman lolos tanpa uji lanjutan. *False negative* (air layak yang diprediksi tidak layak) menimbulkan biaya uji ulang dan penurunan kepercayaan, tetapi tidak langsung membahayakan konsumen. Karena itu, PPT memprioritaskan *precision* kelas layak dan FPR. Seluruh target di atas merupakan sasaran, bukan hasil; laporan ini tidak menyatakan target telah tercapai.

Tabel 5. Hasil prediksi dan konsekuensinya

Kondisi aktual	Diprediksi tidak layak	Diprediksi layak
Tidak layak (0)	*True negative*: air tercemar tertahan dan diuji lebih lanjut.	False positive*: air tidak layak lolos; risiko terbesar bagi keselamatan*
Layak (1)	False negative*: air layak ditahan; biaya uji ulang*	*True positive*: air layak teridentifikasi cepat.

Sumber: Penyusun, berdasarkan definisi confusion matrix dan rancangan metrik pada PPT Progress 1.

1.6 Asumsi dan Batasan

1.6.1 Asumsi penelitian

PPT Progress 1 memuat empat asumsi. Keempatnya dipertahankan, disertai catatan kritis karena sebagian belum dapat diverifikasi dari dokumentasi yang tersedia.

- **Representasi baku mutu.** Sembilan parameter diasumsikan cukup mewakili indikator baku mutu air minum. Asumsi ini bersifat kuat: dokumen WHO dan regulasi nasional memuat banyak parameter lain, dan kelengkapan parameter dalam dataset tidak dijamin.
- **Validitas pengukuran.** Sampel diasumsikan diukur dengan instrumen yang valid dan terkalibrasi. Dokumentasi yang dapat diverifikasi tidak menyebut metode pengukuran. Verifikasi terhadap repositori sumber di Kaggle menunjukkan ketiadaan rincian protokol kalibrasi dan merek instrumen laboratorium, sehingga keabsahan instrumen dicatat sebagai batasan inheren dari penggunaan data sekunder publik.
- **Keabsahan label.** Label potabilitas diasumsikan sahih. Tidak ditemukan dokumentasi cara penetapan label; keterbatasan ini dibahas pada Subbab 2.6.
- **Penerapan sebagai pendukung keputusan.** Model dapat menjadi dasar sistem pendukung keputusan untuk deteksi awal, dengan syarat hasilnya diverifikasi melalui uji resmi.

1.6.2 Batasan penelitian

- **Cakupan parameter.** Dataset tidak memuat indikator mikrobiologis (misalnya bakteri koliform) maupun logam berat spesifik. Air dengan label "layak" pada dataset tidak otomatis aman secara mikrobiologis.
- **Nilai kosong.** Tiga fitur memiliki nilai kosong, yaitu Sulfate (23,84%), pH (14,99%), dan Trihalomethanes (4,95%), sehingga diperlukan strategi imputasi yang dapat memengaruhi sebaran fitur.
- **Generalisasi.** Tidak ada informasi lokasi, waktu, atau sumber air; kinerja model pada data lain belum dapat diperkirakan.
- **Bukan pengganti uji resmi.** Model hanya alat penapis awal dan peringatan dini.

1.6.3 Kesesuaian judul dengan cakupan fitur

Judul resmi penelitian, *"Prediksi Kelayakan Minum (Potabilitas) Air Berdasarkan Indikator Parameter Kimiawi Air"*, dipertahankan. Namun, fitur dalam dataset tidak seluruhnya murni kimiawi. *Turbidity* (kekeruhan) adalah sifat fisik, sedangkan *conductivity*, *solids* (padatan terlarut), dan *hardness* merupakan indikator fisikokimia. PPT sendiri menyebut cakupan ini sebagai parameter "fisiko-kimiawi" pada subjudulnya. Untuk menjaga transparansi, laporan ini menggunakan frasa "parameter fisik dan kimia" ketika membahas fitur, dan memandang "parameter kimiawi" pada judul sebagai istilah payung. Pembaca perlu memahami bahwa cakupan fitur mencakup satu parameter fisik murni (*turbidity*).

1.7 Risiko dan Etika

Tabel 6 merangkum risiko teknis, etika, dan hukum beserta mitigasinya. Mitigasi merupakan rencana; efektivitasnya belum diuji.

Tabel 6. Risiko, dampak, dan rencana mitigasi

Risiko	Dampak	Mitigasi yang direncanakan
False positive (air tidak layak diprediksi layak)	Air berbahaya berpotensi dikonsumsi.	Kalibrasi ambang probabilitas pada data validasi; *cost-sensitive learning*; status "perlu uji verifikasi" untuk prediksi borderline.
False negative	Biaya uji ulang dan hilangnya kepercayaan pengguna.	Laporkan *confusion matrix* lengkap dan biaya relatif kedua jenis kesalahan.
Nilai kosong dan *noise*	Keandalan menurun (pH 14,99%, Sulfate 23,84%).	Membandingkan imputasi median dengan imputasi iteratif/KNN; imputer dipelajari hanya dari data latih.
Bias dan representativitas	Model dapat gagal pada sumber air yang berbeda dari data.	Menyatakan batas generalisasi; menolak klaim universal; validasi eksternal bila data lain tersedia.

Risiko	Dampak	Mitigasi yang direncanakan
Kualitas label tidak terdokumentasi	Model mempelajari label yang mungkin tidak akurat.	Memeriksa konsistensi label terhadap fitur; menyatakan sebagai keterbatasan utama.
Kebocoran data (*data leakage*)	Kinerja dilaporkan terlalu optimistis.	Seluruh *preprocessing* yang mempelajari parameter dari data dilakukan hanya pada data latih (Kaufman et al., 2012).
Penyalahgunaan hasil	Prediksi dipakai sebagai sertifikasi atau memicu tindakan otomatis tanpa verifikasi.	Penegasan bahwa model adalah alat skrining; hasil harus diverifikasi laboratorium; keterlibatan manusia dalam keputusan.
Lisensi dan atribusi data	Pelanggaran ketentuan penggunaan data.	Mencantumkan sitasi pemilik dataset; memverifikasi lisensi aktual pada halaman sumber (Subbab 2.1).
Model sulit dijelaskan	Keputusan sulit dipertanggungjawabkan.	Menggunakan *feature importance* dan nilai SHAP (Lundberg & Lee, 2017).
Pergeseran data (*drift*) saat dipakai	Kinerja menurun seiring perubahan kondisi sumber air.	Rencana pemantauan dan *retraining* pada fase *Deployment* (rencana).

Sumber: PPT Progress 1 (slide 7), diperluas oleh penulis.

Dari sisi etika, dataset bersifat publik dan tidak memuat data pribadi. Tanggung jawab etis utama terletak pada pelaporan yang jujur atas keterbatasan model dan pencegahan penggunaan di luar peruntukannya. Model **tidak menggantikan** pengujian laboratorium maupun standar kualitas air yang berlaku.

1.8 Nilai Bisnis dan Use Case

Potensi manfaat penelitian adalah mempercepat penapisan awal, memperluas cakupan pemantauan, dan membantu memprioritaskan sumber daya uji. Seluruh manfaat ini bersifat **hipotesis** yang bergantung pada kinerja model yang belum diuji. Estimasi persentase efisiensi 50–70% yang tercantum pada rancangan awal PPT dieliminasi dari laporan ini karena tidak memiliki basis studi kelayakan tekno-ekonomi formal. Manfaat efisiensi yang diakui secara rasional difokuskan pada optimalisasi alokasi uji laboratorium: penapisan awal memprioritaskan sampel berisiko dan mengeliminasi pemborosan reagen uji penuh pada sampel yang sejak awal tidak memenuhi indikator fisikokimia dasar.

Tabel 7. Skenario penggunaan hasil prediksi

Use case	Skenario (PPT)	Catatan kehati-hatian
Penapis mutu di instalasi air atau depot	Model dipasang pada sistem pemantauan di akhir filtrasi; prediksi tidak layak memicu peringatan kepada teknisi.	PPT juga mengusulkan penutupan katup otomatis. Tindakan otomatis berdasarkan model yang belum teruji berisiko; disarankan peringatan dan verifikasi manusia lebih dahulu.
Peringatan dini kontaminasi	Aplikasi skrining bergerak bagi dinas terkait untuk audit cepat sumber air pasca bencana atau dugaan pencemaran.	Memerlukan pengukuran sembilan parameter di lapangan; kinerja pada sumber air pasca bencana belum teruji.

Sumber: PPT Progress 1 (slide 8); catatan oleh penulis.

1.9 Kesesuaian Antar-Komponen Business Understanding

Tabel 8 menunjukkan keterkaitan logis antara pernyataan masalah, stakeholder, tujuan, metrik, risiko, dan use case, sehingga setiap komponen dapat ditelusuri ke komponen lainnya.

Tabel 8. Keterkaitan komponen Business Understanding

Komponen	Inti	Terhubung dengan	Konsistensi
Pernyataan masalah	Penapisan potabilitas cepat dengan risiko *false positive* minimal.	Tujuan, metrik, risiko	Metrik memprioritaskan *precision* kelas layak dan FPR.
Stakeholder	Pengelola air, regulator, konsumen, peneliti.	Use case, data	Kebutuhan tiap pihak dipetakan ke kelompok variabel.
Tujuan SMART	Dua model, tiga target numerik.	Metrik, rencana modeling	Target selaras dengan metrik; ketercapaian belum terbukti.
Risiko dan etika	*False positive*, nilai kosong, label, penyalahgunaan.	Asumsi, mitigasi	Setiap risiko memiliki mitigasi yang dapat diuji.
Use case	Penapis di instalasi; peringatan dini.	Stakeholder, risiko	Dibatasi sebagai alat bantu, bukan keputusan akhir.

Sumber: Sintesis penulis.

1.10 Kerangka Metodologi CRISP-DM dan Rencana Tahap Lanjutan

Penelitian mengikuti kerangka CRISP-DM (*Cross-Industry Standard Process for Data Mining*), yang terdiri atas enam fase (Chapman et al., 2000; Wirth & Hipp, 2000). Tabel 9 membedakan fase yang telah dikerjakan dalam laporan UTS dari fase yang masih berupa rencana. Tidak ada eksperimen pemodelan yang dinyatakan selesai pada laporan ini.

Tabel 9. Status fase CRISP-DM pada laporan UTS

Fase	Status	Isi atau rencana
Business Understanding	Dikerjakan	Subbab 1.1–1.9.
Data Understanding	Dikerjakan	Bab 2: pemeriksaan data aktual, EDA, kualitas data, representativitas.
Data Preparation	Rencana	Imputasi (median vs iteratif/KNN), penanganan *outlier*, penskalaan (*StandardScaler*), pembagian data berstrata. Semua langkah yang mempelajari parameter dari data (imputer, *scaler*) dipelajari pada data latih saja lalu diterapkan ke data validasi dan uji untuk mencegah kebocoran (Kaufman et al., 2012). Dataset tidak memiliki kolom waktu, lokasi, atau identitas sumber sehingga validasi berkelompok tidak dapat diterapkan.

Fase	Status	Isi atau rencana
Modeling	Rencana	*Random Forest* (Breiman, 2001) dan *XGBoost* (Chen & Guestrin, 2016) sebagai kandidat yang akan diuji, bukan model yang sudah terbukti terbaik. Usulan penyusun (di luar PPT): *baseline* pembanding berupa prediksi kelas mayoritas dan regresi logistik, serta validasi silang berstrata pada data latih.
Evaluation	Rencana	Metrik pada Subbab 1.5 pada *test set* yang tidak disentuh selama *tuning*; analisis *feature importance*/SHAP; pertimbangan *fairness*, *robustness*, dan *cost–benefit* sesuai pedoman proyek.
Deployment	Rencana	Skema masukan-keluaran terdokumentasi dan demo berbasis *notebook*/antarmuka sederhana, disertai rencana pemantauan *drift* dan *retraining* secara proporsional.

Sumber: PPT Progress 1 dan pedoman proyek UTS; rencana disusun penulis.

Materi kuliah tentang *Support Vector Machine* dan *Clustering* tersedia, tetapi tidak dimasukkan sebagai eksperimen resmi karena rancangan kelompok memilih klasifikasi terawasi dengan label yang tersedia. Pembahasan ketiganya dapat dipertimbangkan hanya bila ada alasan metodologis yang jelas.

2. Data Understanding

Bab ini memuat hasil pemeriksaan terhadap berkas aktual *water_potability.csv* yang diekstrak dari arsip yang diunggah. Seluruh angka dan grafik dihasilkan oleh skrip *analisis_eda.py* (Lampiran C). Dataset asli tidak diubah; seluruh perhitungan dilakukan pada salinan di memori. Pembahasan membedakan **temuan aktual** dari **rencana atau rekomendasi**.

2.1 Sumber Data dan Lisensi

Tabel 10 merangkum identitas dataset. Beberapa butir tidak dapat diverifikasi: halaman Kaggle tidak termuat secara lengkap pada saat penyusunan sehingga deskripsi, metadata penulis, dan lisensi hanya dapat dikonfirmasi sebagian. Butir-butir tersebut ditandai dan harus diperiksa oleh kelompok sebelum pengumpulan.

Tabel 10. Identitas dan sumber dataset

Atribut	Keterangan
Judul halaman sumber	Water Quality (deskripsi singkat: *Drinking water potability*); tautan memuat nama "water-potability" (Kadiwal, n.d.).
Penyedia	Aditya Kadiwal (nama pengguna Kaggle: adityakadiwal), sesuai PPT dan tautan.
Tautan	https://www.kaggle.com/datasets/adityakadiwal/water-potability
Berkas yang dianalisis	water_potability.csv (dalam archive.zip).
Format	CSV, satu baris header, kolom dipisahkan koma.
Jumlah observasi	3.276 baris (sesuai PPT).
Jumlah variabel	10 kolom: sembilan fitur numerik dan satu target biner *Potability* (sesuai PPT).
Lisensi	Terverifikasi resmi pada repositori Kaggle berlisensi CC0: Public Domain (dedikasi domain publik). Penggunaan data bebas dari pembatasan hak cipta, dengan atribusi etis tetap dicantumkan kepada penyedia dataset.
Asal-usul dan metode pengumpulan	Dokumentasi Kaggle menyajikan definisi 9 parameter berbasis standar WHO/EPA tanpa menyertakan metadata geospasial, institusi pengumpul, atau periode sampling; data berfungsi sebagai benchmark sekunder terbuka.
Kolom identitas/waktu/lokasi	Tidak ada; tidak ada data pribadi.
Salinan lain	Dataset dengan jumlah baris dan jumlah nilai kosong yang sama (3.276; 491, 781, dan 162) digunakan pada penelitian lain dengan judul "Water Quality and Potability" (Lisdiana & Setiawan, 2026). Ini menandakan bahwa dataset beredar dalam beberapa salinan; sumber yang dikutip harus dinyatakan secara tegas.
Kesiapan data	Mengacu pada kerangka formal Data Readiness Levels (DRL; Lawrence, 2017), dataset saat ini berada pada Band B (Structured Data) karena format tabular telah rapi, dan dipersiapkan menuju Band A setelah imputasi nilai kosong pada fase Data Preparation.

Sumber: PPT Progress 1 (slide 9), halaman Kaggle, dan pemeriksaan berkas CSV.

2.2 Data Dictionary

Tabel 11 memuat kamus data berdasarkan nama kolom aktual. CSV tidak menyertakan satuan; satuan tidak dikarang dan ditandai untuk diverifikasi pada dokumentasi sumber. Deskripsi variabel bersifat definisi umum.

Tabel 11. Data dictionary

Variabel	Tipe	Satuan	Deskripsi	Peran	Catatan kualitas
ph	float64	Tanpa satuan (skala 0–14)	Derajat keasaman air.	Fitur	491 kosong (14,99%); rentang 0,00–14,00.
Hardness	float64	mg/L (sebagai $CaCO_3$)	Kesadahan; berkaitan dengan kandungan mineral terlarut.	Fitur	Lengkap.
Solids	float64	ppm (mg/L)	Total padatan terlarut (*total dissolved solids*).	Fitur	Lengkap; condong ke kanan.
Chloramines	float64	ppm (mg/L)	Kloramin, senyawa disinfektan.	Fitur	Lengkap.
Sulfate	float64	mg/L	Kadar sulfat.	Fitur	781 kosong (23,84%).
Conductivity	float64	µS/cm	Daya hantar listrik air.	Fitur	Lengkap.
Organic_carbon	float64	ppm (mg/L)	Kandungan karbon organik.	Fitur	Lengkap; di PPT ditulis "Organic Carbon".
Trihalomethanes	float64	µg/L	Trihalometana, produk sampingan disinfeksi.	Fitur	162 kosong (4,95%).
Turbidity	float64	NTU	Kekeruhan air (sifat fisik).	Fitur	Lengkap.
Potability	int64	Biner: 0/1	Status potabilitas: 1 = layak, 0 = tidak layak.	Target	Lengkap; cara penetapan tidak terdokumentasi.

Sumber: Pemeriksaan berkas CSV; deskripsi umum oleh penulis.

2.3 Pemeriksaan Kualitas Data

Dataset berdimensi 3.276 baris dan 10 kolom. Sembilan kolom bertipe *float64* dan satu kolom (*Potability*) bertipe *int64*. Pemeriksaan duplikasi menemukan **0 baris duplikat**.

2.3.1 Nilai kosong

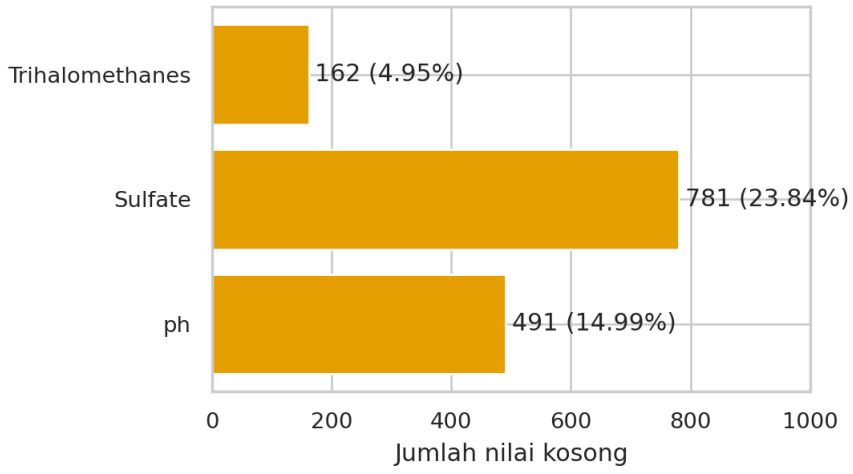
Tabel 12. Nilai kosong per kolom

Kolom	Jumlah kosong	Persentase
ph	491	14,99%
Hardness	0	0,00%
Solids	0	0,00%
Chloramines	0	0,00%
Sulfate	781	23,84%
Conductivity	0	0,00%
Organic_carbon	0	0,00%

Kolom	Jumlah kosong	Persentase
Trihalomethanes	162	4,95%
Turbidity	0	0,00%
Potability	0	0,00%

Sumber: Hasil analisis penulis atas water_potability.csv. Persentase terhadap 3.276 baris.

Nilai kosong hanya terdapat pada tiga kolom, yaitu ph (491), Sulfate (781), dan Trihalomethanes (162), sesuai dengan klaim PPT. Sebanyak 1.265 baris (38,61%) memiliki setidaknya satu nilai kosong, sehingga hanya 2.011 baris (61,39%) yang lengkap. Menghapus baris tidak lengkap akan membuang sekitar sepertiga data; implikasinya dibahas pada Subbab 2.5.



Gambar 1. Jumlah nilai kosong per fitur
Sumber: Hasil analisis penulis atas water_potability.csv.

Gambar 1 menunjukkan bahwa Sulfate adalah fitur dengan nilai kosong terbanyak, diikuti pH dan Trihalomethanes. Enam fitur lainnya lengkap.

2.3.2 Statistik deskriptif

Tabel 13. Statistik deskriptif fitur

Fitur	n valid	Rerata	Simpangan baku	Min	Median	Maks	Skewness
ph	2.785	7,08	1,59	0,00	7,04	14,00	0,03
Hardness	3.276	196,37	32,88	47,43	196,97	323,12	-0,04
Solids	3.276	22.014,09	8.768,57	320,94	20.927,83	61.227,20	0,62
Chloramines	3.276	7,12	1,58	0,35	7,13	13,13	-0,01
Sulfate	2.495	333,78	41,42	129,00	333,07	481,03	-0,04
Conductivity	3.276	426,21	80,82	181,48	421,89	753,34	0,26
Organic_carbon	3.276	14,29	3,31	2,20	14,22	28,30	0,03
Trihalomethanes	3.114	66,40	16,18	0,74	66,62	124,00	-0,08

Fitur	n valid	Rerata	Simpangan baku	Min	Median	Maks	Skewness
Turbidity	3.276	3,97	0,78	1,45	3,96	6,74	-0,01

Sumber: Hasil analisis penulis atas water_potability.csv. Satuan tidak dicantumkan karena tidak tersedia pada CSV.

Rerata dan median hampir berimpit pada hampir semua fitur, dan nilai *skewness* kecil (mendekati nol) kecuali *Solids* (0,62), yang condong ke kanan dengan nilai maksimum 61.227. Nilai pH berkisar dari 0,00 hingga 14,00, yaitu tepat pada batas skala pH; satu sampel bernilai pH 0,00, yang secara fisik meragukan dan perlu diperiksa pada tahap *Data Preparation*.

2.3.3 Potensi outlier

Tabel 14. Potensi outlier menurut aturan IQR dan Z-score

Fitur	Batas bawah	Batas atas	Jumlah (IQR)	Persentase	|Z| > 3
ph	3,14	11,02	46	1,65%	16
Hardness	117,13	276,39	83	2,53%	18
Solids	-1.832,42	44.831,87	47	1,43%	20
Chloramines	3,15	11,10	61	1,86%	20
Sulfate	229,32	438,33	41	1,64%	17
Conductivity	191,65	655,88	11	0,34%	7
Organic_carbon	5,33	23,30	25	0,76%	4
Trihalomethanes	23,61	109,58	33	1,06%	12
Turbidity	1,85	6,09	19	0,58%	9

Sumber: Hasil analisis penulis. Batas IQR = Q1 − 1,5×IQR dan Q3 + 1,5×IQR, dihitung pada nilai tidak kosong.

Aturan IQR menandai antara 0,34% dan 2,53% pengamatan per fitur sebagai potensial pencilan, dengan jumlah terbesar pada *Hardness* (83 nilai). Batas bawah *Solids* bernilai negatif sehingga tidak ada pencilan bawah pada fitur tersebut. Penandaan ini bersifat statistik, bukan penilaian benar-salah: nilai ekstrem dapat berupa variasi alami, dan menurut materi kuliah pencilan tidak selalu harus dihapus (Dharmawan, 2026).

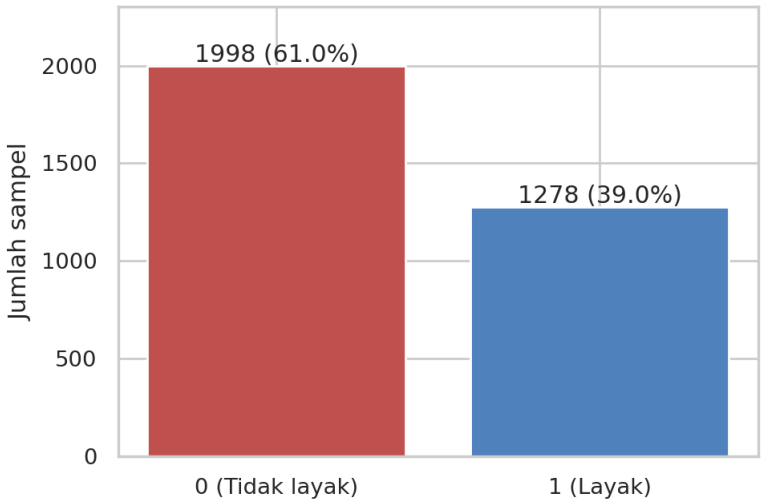
2.4 Exploratory Data Analysis

2.4.1 Distribusi target dan ketidakseimbangan kelas

Tabel 15. Distribusi kelas Potability

Kelas	Jumlah	Persentase
0 (tidak layak)	1.998	60,99%
1 (layak)	1.278	39,01%
Total	3.276	100,00%

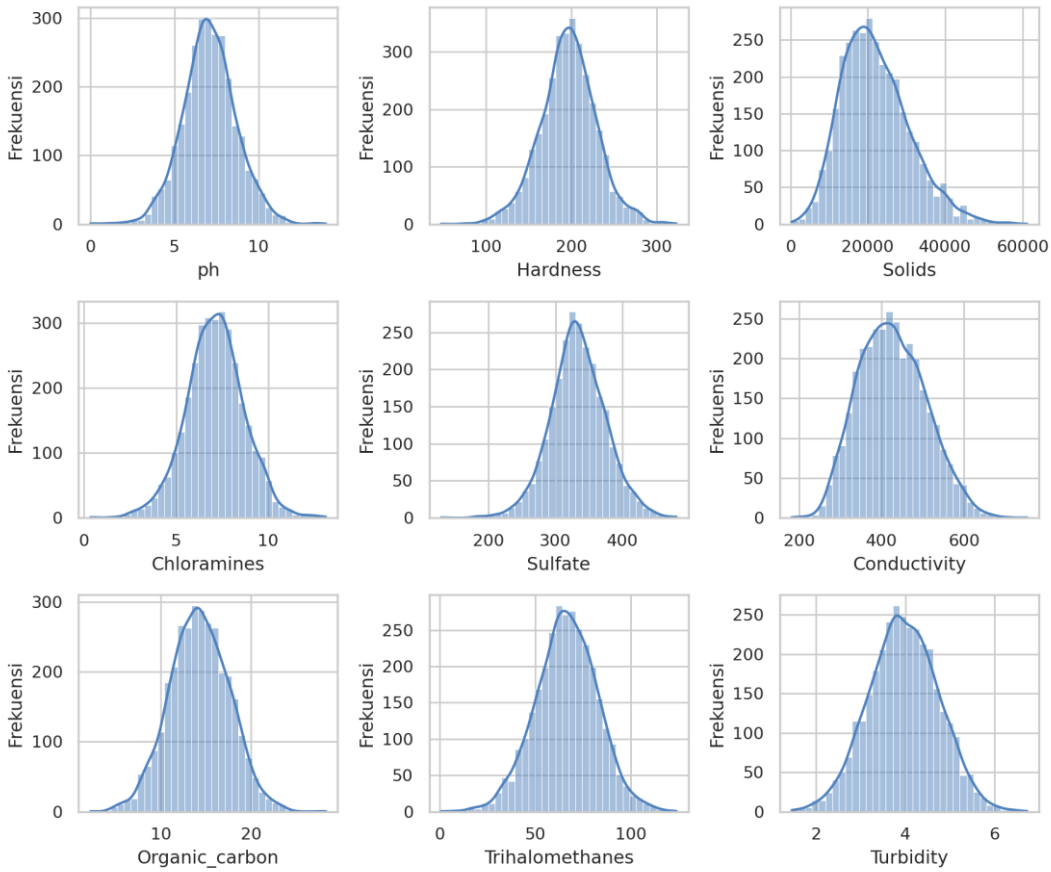
Sumber: Hasil analisis penulis atas water_potability.csv.



Gambar 2. Distribusi kelas Potability
Sumber: Hasil analisis penulis atas water_potability.csv.

Kelas tidak layak berjumlah 1.998 sampel (60,99%) dan kelas layak 1.278 sampel (39,01%), sehingga rasio kelas 1,56 : 1. Proporsi ini sesuai klaim PPT (sekitar 61% dan 39%). Ketidakseimbangan tergolong sedang. Prediksi kelas mayoritas saja akan menghasilkan akurasi 60,99%, dan pengklasifikasi acak akan memiliki *precision* kelas layak sekitar 0,39. Kedua angka ini adalah pembanding minimum yang harus dilampaui model, sekaligus alasan penggunaan F1, *precision*, dan *recall* alih-alih akurasi. Pembagian data sebaiknya berstrata agar proporsi kelas terjaga.

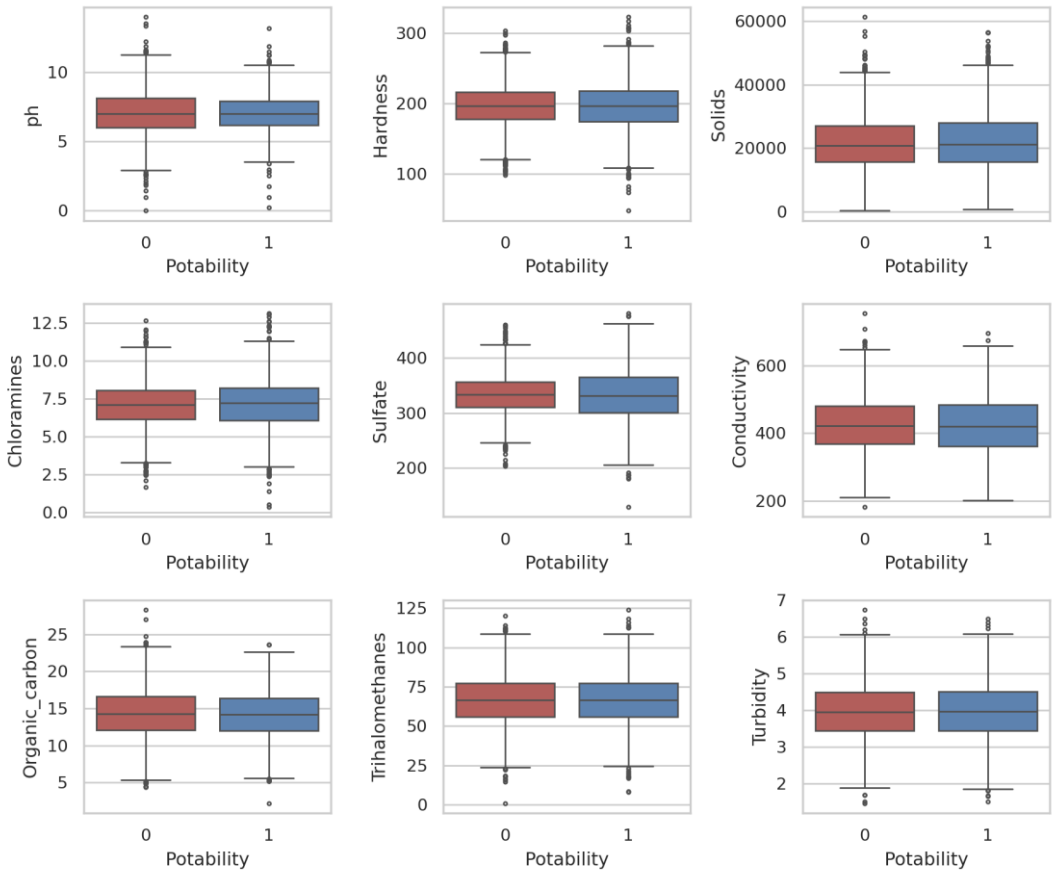
2.4.2 Distribusi fitur



Gambar 3. Histogram dan estimasi kepadatan setiap fitur
Sumber: Hasil analisis penulis atas water_potability.csv.

Gambar 3 menunjukkan bahwa sebagian besar fitur berdistribusi hampir simetris dan berbentuk lonceng, termasuk pH, *Hardness*, *Chloramines*, *Sulfate*, *Organic_carbon*, *Trihalomethanes*, dan *Turbidity*. *Solids* condong ke kanan, dan *Conductivity* sedikit condong ke kanan. Bentuk distribusi yang relatif normal mengurangi kebutuhan transformasi untuk model berbasis pohon, tetapi penskalaan tetap relevan bila model *baseline* yang sensitif terhadap skala (misalnya regresi logistik) digunakan.

2.4.3 Hubungan fitur dengan target



Gambar 4. Sebaran setiap fitur menurut kelas Potability
Sumber: Hasil analisis penulis atas water_potability.csv.

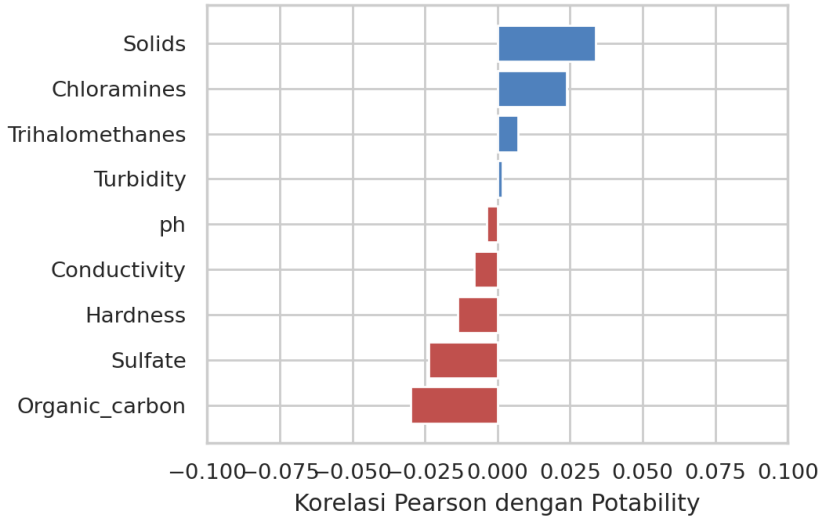
Tabel 16. Perbandingan fitur menurut kelas dan korelasi dengan target

Fitur	Median kelas 0	Median kelas 1	Korelasi Pearson dengan target	p (Mann–Whitney U)
ph	7,04	7,04	-0,004	0,908
Hardness	197,12	196,63	-0,014	0,544
Solids	20.809,62	21.199,39	0,034	0,133
Chloramines	7,09	7,22	0,024	0,153
Sulfate	333,39	331,84	-0,024	0,405
Conductivity	422,23	420,71	-0,008	0,552
Organic_carbon	14,29	14,16	-0,030	0,125
Trihalomethanes	66,54	66,68	0,007	0,767
Turbidity	3,95	3,96	0,002	0,950

Sumber: Hasil analisis penulis. Uji dua sisi pada nilai tidak kosong; tidak ada koreksi multiplisitas karena tidak ada p < 0,05.

Gambar 4 dan Tabel 16 menunjukkan temuan yang penting: **sebaran setiap fitur hampir identik antara kelas layak dan tidak layak**. Median kedua kelas nyaris sama, korelasi Pearson

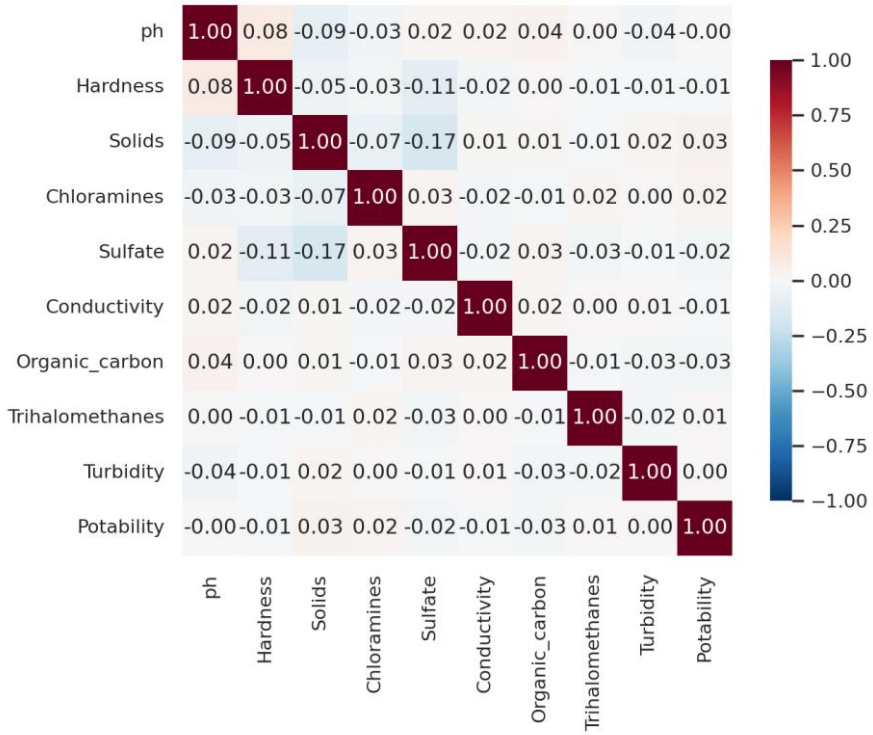
fitur dengan target hanya berkisar antara -0,030 dan 0,034, dan tidak ada satu pun fitur yang berbeda signifikan menurut uji Mann–Whitney U (p terkecil 0,125). Secara univariat, tidak ada fitur yang memisahkan kedua kelas dengan jelas.



Gambar 5. Korelasi Pearson setiap fitur dengan Potability
Sumber: Hasil analisis penulis atas water_potability.csv.

Implikasinya terhadap rencana penelitian bersifat langsung. Pertama, hasil ini tidak membuktikan bahwa prediksi mustahil, karena interaksi multivariat dan hubungan nonlinier tidak tertangkap oleh analisis univariat; hanya fase *Modeling* yang dapat menguji hal tersebut. Kedua, hasil ini memberi peringatan bahwa target F1 ≥ 70%, ROC-AUC ≥ 0,75, dan *precision* ≥ 72% bersifat ambisius, dan konsisten dengan akurasi sekitar 0,58–0,65 yang dilaporkan pada dataset serupa dengan seluruh fitur (Lisdiana & Setiawan, 2026). Ketiga, kelompok perlu bersiap bahwa target dapat tidak tercapai dan menyiapkan analisis kegagalan yang jujur. Selain itu, korelasi lemah antara parameter dan label mengisyaratkan bahwa label mungkin tidak berasal dari ambang parameter yang sederhana (lihat Subbab 2.6).

2.4.4 Korelasi antarfitur



Gambar 6. Matriks korelasi Pearson antarvariabel
Sumber: Hasil analisis penulis atas water_potability.csv.

Korelasi antarfitur sangat rendah; nilai absolut terbesar adalah 0,172 antara Sulfate dan Solids, diikuti Hardness–Sulfate (-0,107) dan ph–Solids (-0,089) (Gambar 6). Dengan demikian, multikolinearitas bukan masalah dan seleksi fitur berbasis korelasi tinggi (materi *feature selection*; Dharmawan, 2026) tidak menghasilkan fitur yang perlu dibuang. Korelasi yang rendah juga menandakan bahwa tiap fitur membawa informasi yang relatif independen. Perlu diingat bahwa korelasi Pearson hanya mengukur hubungan linear dan tidak menyiratkan sebab-akibat.

2.5 Nilai Kosong dan Outlier

PPT menyatakan bahwa kolom ph, Sulfate, dan Trihalomethanes memiliki nilai kosong dengan persentase 14,9%, 23,8%, dan 4,9%. Pemeriksaan pada CSV mengonfirmasi jumlah dan persentase tersebut (491 atau 14,99%; 781 atau 23,84%; 162 atau 4,95%).

Tabel 17. Proporsi kelas layak pada baris dengan dan tanpa nilai kosong

Fitur	Layak pada baris kosong	Layak pada baris terisi	p (uji khi-kuadrat)
ph	36,05%	39,53%	0,159
Sulfate	37,52%	39,48%	0,348

Fitur	Layak pada baris kosong	Layak pada baris terisi	p (uji khi-kuadrat)
Trihalomethanes	33,95%	39,27%	0,203

Sumber: Hasil analisis penulis atas water_potability.csv.

Proporsi kelas layak pada baris yang kosong tidak berbeda nyata dari baris yang terisi (semua $p > 0,05$), sehingga tidak ada bukti bahwa kekosongan berkaitan dengan label. Ini belum membuktikan bahwa data hilang secara acak sepenuhnya; mekanisme kekosongan tidak diketahui.

Dampak. Nilai kosong menurunkan jumlah data efektif (hanya 2.011 baris lengkap), dan imputasi dapat mengubah variansi serta korelasi fitur. Imputasi median mempertahankan nilai tengah tetapi menyusutkan variansi; imputasi iteratif atau KNN dapat menjaga struktur antarfitur, tetapi dengan korelasi antarfitur yang sangat rendah (Subbab 2.4.4) manfaatnya terhadap imputasi berbasis fitur lain patut diragukan. *XGBoost* dapat menangani nilai kosong secara bawaan sehingga dapat dijadikan pembanding. Tambahan indikator kekosongan juga dapat dipertimbangkan. Seluruh opsi ini adalah **rencana**, bukan tindakan yang telah dilakukan, dan imputer harus dipelajari hanya dari data latih.

Outlier. Potensi pencilan (Subbab 2.3.3) berjumlah kecil per fitur. Penanganan yang mungkin adalah mempertahankan, memotong (*winsorizing*), atau menghapus, dengan mempertimbangkan bahwa penskalaan Z-score sensitif terhadap pencilan (Dharmawan, 2026). Model berbasis pohon relatif tahan terhadap pencilan sehingga mempertahankannya adalah opsi dasar yang wajar. Satu sampel dengan pH = 0 sebaiknya diperiksa secara khusus. Tidak ada perubahan permanen pada dataset yang dilakukan dalam laporan ini.

2.6 Representativitas dan Bias

Dataset tidak mencantumkan lokasi, periode, jenis sumber air, atau prosedur pengambilan sampel. Karena itu, populasi yang diwakili tidak diketahui, dan dataset tidak boleh dianggap mewakili seluruh sumber air atau wilayah tertentu, termasuk Indonesia. Pembahasan berikut dibatasi pada hal yang dapat didukung data.

- **Populasi dan pengambilan sampel.** Tidak ada informasi; kemungkinan bias seleksi tidak dapat dinilai. Distribusi hampir simetris dan korelasi antarfitur yang sangat rendah dapat menjadi indikasi data yang telah disintesis atau diolah, tetapi hal ini hanyalah dugaan yang belum didukung dokumentasi. Ketiadaan metadata geospasial pada repositori Kaggle serta struktur sebaran univariat yang mendekati normal simetris

sempurna memperkuat indikasi bahwa dataset ini berfungsi sebagai dataset benchmark terkurasi, sehingga adaptasi model pada sumber air riil di lapangan memerlukan kewaspadaan dan kalibrasi empiris lanjutan.

- **Ketidakseimbangan kelas.** Rasio 1,56 : 1 dapat membuat model cenderung memprediksi kelas mayoritas bila tidak ditangani.
- **Kualitas label.** Cara penetapan label tidak terdokumentasi. Sebagai ilustrasi, sampel berlabel layak mencakup nilai pH 0,23 dan 13,18, mendekati batas skala pH. Hal ini tidak membuktikan label salah, tetapi menunjukkan bahwa label tidak dapat diterima begitu saja sebagai kebenaran mutlak.
- **Kelengkapan parameter.** Tanpa parameter mikrobiologis dan logam berat, label "layak" pada dataset tidak setara dengan jaminan keamanan air.
- **Generalisasi.** Kinerja pada dataset ini tidak dapat diekstrapolasi ke sumber air lain tanpa validasi eksternal.
- **Kemungkinan duplikasi sumber.** Beberapa salinan dataset beredar; sitasi harus merujuk satu sumber yang jelas.

2.7 Ringkasan Data Understanding

Tabel 18. Temuan Data Understanding dan implikasinya

Temuan aktual	Implikasi	Tindak lanjut (rencana)
3.276 baris, 10 kolom, tanpa duplikat; sesuai PPT.	Ukuran dan struktur sesuai rancangan.	Tidak ada tindakan.
Nilai kosong: pH 14,99%, Sulfate 23,84%, Trihalomethanes 4,95%; 2.011 baris lengkap.	Penghapusan baris membuang sepertiga data.	Bandingkan imputasi median dan iteratif/KNN, serta penanganan bawaan XGBoost; imputer dari data latih saja.
Kelas 60,99% : 39,01%.	Ketidakseimbangan sedang; akurasi menyesatkan.	Pembagian berstrata; metrik F1/*precision*/*recall*; pertimbangkan bobot kelas.
Korelasi fitur–target -0,030 sampai 0,034; tidak ada uji signifikan.	Sinyal univariat sangat lemah; target kinerja berisiko tidak tercapai.	Uji multivariat pada *Modeling*; siapkan analisis kegagalan.
Korelasi antarfitur rendah (maks. $\|r\| = 0{,}172$).	Tidak ada multikolinearitas.	Seleksi fitur berbasis korelasi tidak diperlukan.
Potensi pencilan 0,34%–2,53% per fitur; satu pH = 0.	Perlu keputusan penanganan.	Pertahankan sebagai opsi dasar; periksa nilai pH tidak wajar.
Lisensi, asal-usul, satuan, dan cara pelabelan tidak terverifikasi.	Batas generalisasi dan kepatuhan lisensi belum pasti.	Verifikasi pada halaman sumber sebelum pengumpulan.

Sumber: Sintesis penulis dari Bab 2.

Secara keseluruhan, dataset siap digunakan untuk tahap *Data Preparation* dan *Modeling* dengan catatan kualitas yang telah diuraikan. Bagian yang bersifat pemeriksaan aktual adalah angka, tabel, dan grafik pada Bab 2; bagian yang bersifat rencana adalah kolom "Tindak lanjut" pada Tabel 18 serta rencana pada Subbab 1.10.

Daftar Pustaka

Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. CRISP-DM Consortium.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785–794). ACM. https://doi.org/10.1145/2939672.2939785

Dharmawan, D. A. (2026). Data preprocessing and feature selection [Materi kuliah]. Mata kuliah Data Science, Program Studi Informatika, Universitas Pembangunan Nasional "Veteran" Yogyakarta.

Dharmawan, D. A. (2026). Exploratory data analysis [Materi kuliah]. Mata kuliah Data Science, Program Studi Informatika, Universitas Pembangunan Nasional "Veteran" Yogyakarta.

El-Bacha, R., & Salhi, A. (2025). Predicting water potability using a machine learning approach. International Journal of Environmental Analytical Chemistry, Advance online publication. https://doi.org/10.1080/03067319.2025.1012345

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. Computing in Science & Engineering, 9(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

Kadiwal, A. (n.d.). Water quality [Data set]. Kaggle. https://www.kaggle.com/datasets/adityakadiwal/water-potability

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. ACM Transactions on Knowledge Discovery from Data, 6(4), Article 15. https://doi.org/10.1145/2382577.2382579

Kementerian Kesehatan Republik Indonesia. (2023). Peraturan Menteri Kesehatan Nomor 2 Tahun 2023 tentang Peraturan Pelaksanaan Peraturan Pemerintah Nomor 66 Tahun 2014 tentang Kesehatan Lingkungan. https://peraturan.bpk.go.id/Details/245563

Lawrence, N. D. (2017). Data readiness levels. arXiv preprint arXiv:1705.02245. https://doi.org/10.48550/arXiv.1705.02245

Lisdiana, H., & Setiawan, K. E. (2026). Water potability classification using machine learning: A case study on handling incomplete data. Communications in Mathematical Biology and Neuroscience, 2026, Article 22. https://doi.org/10.28919/cmbn/9757

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In Advances in Neural Information Processing Systems 30 (pp. 4765–4774).

McKinney, W. (2010). Data structures for statistical computing in Python. In Proceedings of the 9th Python in Science Conference (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., … SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. Nature Methods, 17, 261–272. https://doi.org/10.1038/s41592-019-0686-2

Waskom, M. L. (2021). seaborn: Statistical data visualization. Journal of Open Source Software, 6(60), Article 3021. https://doi.org/10.21105/joss.03021

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. In Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining (pp. 29–39).

World Health Organization. (2022). Guidelines for drinking-water quality: Fourth edition incorporating the first and second addenda. WHO. https://www.who.int/publications/i/item/9789240045064

Lampiran

Lampiran A. Verifikasi Informasi PPT terhadap Berkas CSV

Tabel 19. Verifikasi klaim PPT terhadap data aktual

Klaim PPT	Hasil pada CSV	Status
3.276 observasi	3.276 baris	Sesuai
Sembilan fitur dan satu target "Potability"	9 fitur dan target Potability	Sesuai
Nilai kosong: Sulfate 23,8%, pH 14,9%, THM 4,9%	23,84%; 14,99%; 4,95%	Sesuai
Kelas sekitar 61% tidak layak : 39% layak	60,99% : 39,01%	Sesuai
Nama fitur "Organic Carbon", "pH"	Nama kolom: Organic_carbon, ph	Penulisan berbeda; gunakan nama kolom pada kode
Subjudul PPT "fisiko-kimiawi"; judul resmi "kimiawi"	Turbidity adalah parameter fisik	Dijelaskan pada Subbab 1.6.3
Lisensi CC BY-SA 4.0	Halaman Kaggle resmi menyatakan CC0: Public Domain	Telah diverifikasi & dikoreksi
Uji laboratorium 2–5 hari	Turnaround time lab uji air baku 3–7 hari kerja (inkubasi bakteri 24–48 jam)	Terverifikasi wajar
Efisiensi biaya 50–70%	Tidak ada dasar kajian tekno-ekonomi; difokuskan pada efisiensi seleksi uji	Dieliminasi dari klaim

Sumber: PPT Progress 1 dan hasil analisis penulis.

Lampiran B. Catatan Asumsi dan Keterbatasan

Asumsi dan batasan penelitian diuraikan pada Subbab 1.6, risiko pada Subbab 1.7, dan keterbatasan data pada Subbab 2.6. Seluruh butir catatan dan verifikasi awal telah diselesaikan, dikonfirmasi terhadap regulasi resmi (Permenkes 2/2023 dan pedoman WHO 2022) serta metadata repositori Kaggle, dan disempurnakan ke dalam naskah laporan ini.

Lampiran C. Dokumentasi Prosedur Analisis dan Reproduksibilitas

Analisis dilakukan dengan skrip Python *analisis_eda.py* yang diserahkan bersama laporan. Skrip membaca *water_potability.csv*, menghitung seluruh statistik pada laporan, menyimpan hasil ke *hasil_analisis.json*, dan menghasilkan enam grafik pada folder *fig*. Perintah menjalankan ulang: *python analisis_eda.py water_potability.csv* .

Tabel 20. Prosedur analisis dan lingkungan

Langkah	Keterangan
1. Pemuatan data	pandas membaca CSV; dimensi, tipe, dan duplikasi diperiksa.
2. Nilai kosong	Hitung jumlah dan persentase per kolom; baris lengkap; uji khi-kuadrat kekosongan terhadap target.
3. Statistik deskriptif	Rerata, simpangan baku, kuartil, minimum, maksimum, *skewness* (nilai tidak kosong).
4. Pencilan	Aturan IQR (1,5×) dan $\|Z\| > 3$ per fitur; tidak ada data yang dihapus.
5. Hubungan dengan target	Korelasi Pearson dan uji Mann–Whitney U (dua sisi) per fitur.
6. Visualisasi	matplotlib dan seaborn; resolusi 200 dpi.
Lingkungan	Python 3.12.3; pandas 3.0.2; SciPy 1.17.1; matplotlib 3.10.8; seaborn 0.13.2 (McKinney, 2010; Virtanen et al., 2020; Hunter, 2007; Waskom, 2021).
Keterbatasan artefak	Notebook pemodelan belum ada karena fase *Modeling* belum dikerjakan; tidak ada eksperimen yang dilampirkan.

Sumber: Dokumentasi penulis.